Prédiction de la Volatilité Réalisée par Modèle HAR-RV Étendu avec XGBoost

Corrections Méthodologiques, Features Intraday
et Fenêtre Adaptative

Paul MONTIER

Mars 2026

Résumé. Ce papier présente une extension du modèle HAR-RV (Corsi, 2009) pour la prédiction de la volatilité réalisée à 5 jours sur un univers de 20 actions du S&P 500. Nous utilisons des données intraday à 1 minute (IEX Cloud, 2020–2026) et un modèle XGBoost avec 20 features couvrant cinq catégories : volatilité multi-échelle, microstructure, moments supérieurs, effet de levier et features cross-sectionnelles. Nous documentons trois biais méthodologiques courants (chevauchement des targets, couplage target-feature, utilisation de proxys journaliers) qui gonflent artificiellement l'Information Coefficient (IC) de 0.61 à 0.29 réel. Après corrections, trois extensions améliorent le signal genuïne : (i) les moments supérieurs intraday (+6.5 %), (ii) une fenêtre d'entraînement adaptative basée sur le VIX (+8.7 %), et (iii) des features de *leverage effect* (+18.9 %), portant l'IC final à 0.394 (+35.4 % cumulatif). Une étude d'ablation révèle que la corrélation rolling rendement–volatilé (Leverage_22d), bien que non significative en univarié, constitue le principal moteur de gain via ses interactions non linéaires dans les arbres de décision.

Table des matières

1 Introduction **2**

2 Revue de littérature **6**
- 2.1 Le modèle HAR-RV et ses fondements . . . 6
- 2.2 Composantes de jumps et bipower variation . . . 6
- 2.3 Moments supérieurs réalisés . . . 7
- 2.4 Effet de levier . . . 7

3 Données **8**
- 3.1 Univers et période . . . 8
- 3.2 Sources . . . 8
- 3.3 Statistiques descriptives . . . 9

4 Méthodologie **9**
- 4.1 Volatilité réalisée intraday . . . 9
- 4.2 Construction des features . . . 10
- 4.3 Variable cible . . . 12
- 4.4 Modèle XGBoost . . . 12
- 4.5 Protocole walk-forward avec purging . . . 13
- 4.6 Fenêtre d'entraînement adaptative . . . 13
- 4.7 Métriques d'évaluation . . . 14

5 Corrections méthodologiques **14**
- 5.1 Chevauchement des targets (data leakage) . . . 15
- 5.2 Couplage target-feature . . . 15
- 5.3 Proxy de volatilité . . . 15
- 5.4 Impact cumulé des corrections . . . 16

6 Extensions et résultats **17**
- 6.1 Features moments supérieurs (v4) . . . 17
- 6.2 Fenêtre adaptative VIX (v5) . . . 17
- 6.3 Features leverage (v6) . . . 18
- 6.4 Étude d'ablation . . . 19
- 6.5 Progression cumulée . . . 21

7 Discussion **21**
- 7.1 Forces de l'approche . . . 21
- 7.2 Limites . . . 22
- 7.3 Perspectives . . . 22

8 Conclusion **23**

1 Introduction

La volatilité des marchés financiers est l'une des grandeurs les plus étudiées en finance quantitative, et pour cause : elle intervient dans presque toutes les décisions d'investissement. Un gestionnaire de portefeuille a besoin de prévoir la volatilité future pour calibrer ses positions ; un trader d'options doit estimer si la volatilité implicite sur-évalue ou sous-évalue la volatilité qui se réalisera effectivement ; un risk manager doit anticiper les régimes de stress pour ajuster ses limites. La question de la prédictibilité de la volatilité n'est donc pas purement académique : elle a des conséquences directes sur la performance et la gestion du risque.

Contrairement aux rendements, dont la prédictibilité reste débattue, la volatilité présente des propriétés statistiques qui la rendent nettement plus prévisible. Elle exhibe une forte persistance (la volatilité élevée tend à rester élevée), un clustering temporel (les périodes de forte volatilité se regroupent), et une mémoire longue (les chocs de volatilité mettent des semaines voire des mois à se dissiper). Ces régularités empiriques suggèrent qu'un modèle bien conçu devrait pouvoir extraire un signal prédictif significatif.

Le modèle HAR-RV (*Heterogeneous Autoregressive model of Realized Volatility*), introduit par Corsi (2009), est devenu un standard dans la littérature pour la prédiction de la volatilité réalisée. Son succès repose sur une idée élégante : plutôt que de modéliser la mémoire longue par des processus fractionnaires complexes, il suffit de décomposer le signal de volatilité en trois composantes correspondant à trois horizons temporels — journalier, hebdomadaire et mensuel. Cette décomposition reflète l'hypothèse des marchés hétérogènes de Müller et al. (1997) : les day-traders réagissent à la volatilité récente (horizon court), les gestionnaires de portefeuille ajustent leurs positions sur un horizon hebdomadaire, et les investisseurs institutionnels raisonnent à l'échelle mensuelle ou trimestrielle. La superposition de ces comportements hétérogènes crée la structure de mémoire longue observée dans les séries de volatilité.

Cependant, le modèle HAR-RV original repose sur une régression linéaire, ce qui l'empêche de capturer deux types de phénomènes importants. Premièrement, les non-linéarités : la réponse de la volatilité future à un choc dépend de l'état du marché (régime calme vs crise), et cette dépendance à l'état n'est pas capturable linéairement. Deuxièmement, les interactions entre features : l'impact de l'asymétrie intraday sur la volatilité future peut dépendre du niveau de VIX, une interaction que seul un modèle non linéaire peut exploiter.

Dans ce papier, nous proposons une extension du modèle HAR-RV qui répond à ces limitations. Nous utilisons XGBoost (Chen and Guestrin, 2016) comme modèle d'apprentissage — un algorithme de *gradient boosting* qui excelle précisément dans la capture d'interactions non linéaires entre features — et nous étendons l'ensemble des features de 3 à 20, en exploitant pleinement les données intraday à 1 minute.

Au-delà de l'amélioration du modèle, ce travail apporte un éclairage méthodologique important. Nous montrons que trois biais courants dans l'évaluation des modèles de volatilité — le chevauchement des targets dans le walk-forward, le couplage entre la cible et les features, et l'utilisation de proxys journaliers inefficients — peuvent gonfler artificiellement l'Information Coefficient de plus de 50 %. Ce diagnostic est essentiel : améliorer un modèle n'a de sens que si l'on mesure correctement la performance de départ.

Définitions et concepts clés

Avant d'entrer dans le détail de notre approche, nous définissons les concepts fondamentaux nécessaires à la compréhension de ce travail.

Volatilité. La volatilité mesure l'amplitude des fluctuations du prix d'un actif financier sur une période donnée. Plus formellement, c'est l'écart-type (ou la variance) des rendements de l'actif. Une volatilité élevée signifie que le prix subit de larges oscillations — à la hausse comme à la baisse — ce qui traduit une forte incertitude du marché. La volatilité n'est pas directement observable : elle doit être *estimée* à partir des données de prix, ce qui amène à distinguer plusieurs types de volatilité.

Volatilité réalisée (Realized Volatility, RV). La volatilité réalisée est une mesure *ex post* de la volatilité, calculée à partir des rendements observés. Dans notre cas, nous utilisons des données intraday à 1 minute : la RV journalière est la racine carrée de la somme des carrés des rendements logarithmiques 1-minute sur la journée :

$$\mathrm{RV}_t = \sqrt{\sum_{i=1}^{n_t} r_{t,i}^2}, \quad r_{t,i} = \ln\left(\frac{P_{t,i}}{P_{t,i-1}}\right) \tag{1}$$

où $P_{t,i}$ est le prix à la i-ème minute du jour t et $n_t \approx 350$ le nombre d'observations intraday. Cette mesure est bien plus précise qu'un simple rendement journalier car elle agrège des centaines d'observations plutôt qu'une seule. La RV est le standard académique pour mesurer la volatilité ex post depuis les travaux de Andersen et al. (2003).

Volatilité implicite et VIX. À la différence de la RV qui mesure la volatilité *passée*, la volatilité implicite reflète les *anticipations* du marché sur la volatilité future. Elle est extraite des prix des options : plus les options sont chères, plus les investisseurs anticipent de la volatilité. Le **VIX** (*CBOE Volatility Index*), souvent appelé "indice de la peur", est la volatilité implicite à 30 jours du S&P 500, exprimée en pourcentage annualisé. Un VIX de 15 correspond à un marché calme ; au-dessus de 25, le marché est considéré comme stressé ; il a atteint 82 en mars 2020 (début du COVID). Dans notre modèle, le VIX sert à la fois de feature prédictive et d'indicateur de régime pour la fenêtre d'entraînement adaptative.

Rendement logarithmique. Le rendement logarithmique (ou log-return) entre deux prix P_{t-1} et P_t est défini comme $r_t = \ln(P_t/P_{t-1})$. Par rapport au rendement arithmétique $(P_t - P_{t-1})/P_{t-1}$, le log-return présente deux avantages techniques : (i) il est *additivement composable* — le rendement sur n périodes est la somme des rendements individuels — et (ii) il est symétrique — une hausse de $+5\%$ suivie d'une baisse de -5% ramène approximativement au prix initial. Ces propriétés simplifient considérablement l'analyse statistique.

Données intraday (haute fréquence). Les données intraday sont des observations de prix enregistrées à l'intérieur d'une journée de trading, à des intervalles réguliers (1 minute, 5 minutes, etc.). Contrairement aux données journalières qui ne fournissent qu'une seule observation par

jour (le prix de clôture), les données intraday à 1 minute fournissent environ 390 observations par jour (6h30 de trading). Cette granularité permet de mesurer la volatilité beaucoup plus précisément et de calculer des statistiques inaccessibles avec les seuls prix journaliers, comme la microstructure du marché, l'asymétrie intraday des rendements, ou la décomposition de la variance en composante continue et sauts.

Modèle HAR-RV. Le modèle HAR-RV (*Heterogeneous Autoregressive model of Realized Volatility*), introduit par Corsi (2009), prédit la volatilité réalisée future comme une combinaison linéaire de la RV passée calculée à trois échelles temporelles : journalière ($\mathrm{RV}^{(d)}$), hebdomadaire ($\mathrm{RV}^{(w)}$, moyenne 5 jours) et mensuelle ($\mathrm{RV}^{(m)}$, moyenne 22 jours). L'idée directrice est que différents types d'acteurs de marché opèrent à des horizons différents (day-traders, gestionnaires de portefeuille, investisseurs institutionnels), et que la volatilité agrégée résulte de la superposition de leurs comportements. Cette décomposition multi-échelle capture la propriété de *mémoire longue* de la volatilité (les chocs de vol se dissipent lentement) sans recourir à des modèles fractionnaires complexes.

XGBoost et gradient boosting. XGBoost (*eXtreme Gradient Boosting*, Chen and Guestrin, 2016) est un algorithme d'apprentissage automatique de la famille du *gradient boosting*. Le principe est de construire séquentiellement un ensemble d'arbres de décision, où chaque nouvel arbre corrige les erreurs résiduelles des arbres précédents. Un arbre de décision individuel partitionne l'espace des features par des règles binaires (e.g., "si VIX > 20 alors...") ; l'ensemble de N arbres produit une prédiction finale par sommation :

$$\hat{y}_t = \sum_{k=1}^{N} f_k(\mathbf{x}_t) \tag{2}$$

où f_k est le k-ème arbre et $\mathbf{x}_t$ le vecteur de features au jour t. L'avantage de XGBoost par rapport à une régression linéaire est sa capacité à capturer des *non-linéarités* (l'impact d'une feature peut dépendre de son niveau) et des *interactions* (l'impact d'une feature peut dépendre de la valeur d'une autre feature). Dans notre contexte, cela signifie par exemple que l'impact de l'asymétrie réalisée sur la volatilité future peut dépendre du régime de marché (VIX), une interaction que seul un modèle non linéaire peut exploiter.

Features (variables explicatives). En apprentissage automatique, une *feature* est une variable calculée à partir des données brutes et fournie en entrée du modèle pour l'aider dans sa prédiction. Dans notre cas, les 20 features du modèle sont des statistiques calculées à partir de l'historique des prix (rendements, volatilités à différentes échelles, volumes, asymétrie, etc.). Le choix des features — quelles informations donner au modèle — est crucial : trop peu de features et le modèle manque d'information ; trop de features non pertinentes et le modèle risque le surapprentissage (overfitting), c'est-à-dire qu'il apprend des patterns spécifiques à l'échantillon d'entraînement qui ne se généralisent pas.

Walk-forward et purging. Le *walk-forward* est un protocole d'évaluation adapté aux séries temporelles : pour chaque jour de test t, le modèle est entraîné uniquement sur les données

antérieures à t, puis évalué sur le jour t. Cela reproduit les conditions réelles d'utilisation où l'on ne connaît pas le futur. Le *purging* est un raffinement supplémentaire : lorsque la variable cible est calculée sur un horizon de plusieurs jours (5 jours dans notre cas), il existe un chevauchement temporel entre les dernières observations d'entraînement et le point de test. Le purging élimine ce chevauchement en introduisant un "gap" entre les données d'entraînement et le point de test, évitant ainsi une fuite d'information (*data leakage*) subtile.

Information Coefficient (IC). L'IC est la métrique centrale de ce travail. Il s'agit de la corrélation de rang de Spearman entre les prédictions du modèle et les valeurs réalisées :

$$\mathrm{IC} = \rho_{\mathrm{Spearman}}(\hat{y}, y) \tag{3}$$

Contrairement à la corrélation de Pearson, l'IC mesure la qualité du *classement* des prédictions plutôt que leur précision absolue. Un IC de 0 signifie que les prédictions ne contiennent aucune information ; un IC de 1 signifierait un classement parfait. En pratique, un IC de 0.10 est considéré comme exploitable, un IC de 0.20 comme bon, et un IC au-delà de 0.30 comme excellent. Notre modèle atteint un IC de 0.394.

Effet de levier (*leverage effect*). Découvert par Black (1976) et formalisé par Christie (1982), l'effet de levier désigne l'observation empirique que les baisses de prix sont associées à des hausses de volatilité *plus fortes* que les hausses de prix de même amplitude. Autrement dit, la relation rendement–volatilité est asymétrique et négative. Deux mécanismes l'expliquent : (i) quand le prix d'une action baisse, son ratio d'endettement (dette/capitalisation) augmente mécaniquement, accroissant le risque perçu ; (ii) les baisses déclenchent des ventes forcées (stop-loss, appels de marge) qui amplifient la volatilité. Cet effet est l'un des faits stylisés les plus robustes de la finance empirique.

Moments supérieurs (skewness, kurtosis). Au-delà de la moyenne (moment d'ordre 1) et de la variance (moment d'ordre 2), les moments d'ordre supérieur caractérisent la *forme* de la distribution des rendements. L'*asymétrie* (skewness, moment d'ordre 3) mesure la dissymétrie de la distribution : une skewness négative signifie que les rendements extrêmes négatifs sont plus fréquents ou plus amples que les positifs (risque de crash). Le *kurtosis* (moment d'ordre 4) mesure l'épaisseur des queues de distribution : un kurtosis élevé (leptokurtique) signale une probabilité anormalement élevée de rendements extrêmes. Les distributions de rendements financiers présentent généralement une skewness négative et un kurtosis supérieur à celui d'une loi normale ("*fat tails*").

Jumps (sauts de prix). Un *jump* est un mouvement de prix brutal et discontinu, généralement causé par une annonce macroéconomique, une publication de résultats d'entreprise, ou un événement géopolitique. Contrairement aux mouvements "diffusifs" (oscillations continues et graduelles), les jumps représentent des ruptures ponctuelles dans le processus de prix. La *bipower variation* (BPV) de Barndorff-Nielsen and Shephard (2004) permet de séparer la composante continue de la volatilité de la composante de sauts, une distinction cruciale car ces deux com-

posantes ont des dynamiques futures très différentes : la composante continue est persistante et prévisible, tandis que les jumps sont transitoires et largement imprévisibles.

Contributions. Ce travail apporte trois contributions principales :

1. **Diagnostic méthodologique.** Nous identifions et corrigeons trois biais courants dans l'évaluation des modèles de volatilité : le chevauchement des targets, le couplage target-feature, et l'utilisation de proxys journaliers. Nous quantifions leur impact respectif et montrons qu'ils expliquent 52 % du signal apparent.
2. **Features étendues.** Nous proposons un ensemble de 20 features organisées en cinq catégories théoriquement motivées, alimentées par des données à 1 minute. Chaque ajout est validé par une comparaison équitable (même période, même protocole).
3. **Fenêtre adaptative.** Nous introduisons une fenêtre d'entraînement dont la taille s'adapte au régime de volatilité implicite (VIX) via interpolation linéaire, reposant sur l'idée que la pertinence des données historiques dépend de la stabilité du régime courant.

2 Revue de littérature

2.1 Le modèle HAR-RV et ses fondements

La volatilité réalisée, mesurée à partir de données haute fréquence, est devenue le standard pour estimer la volatilité ex-post depuis les travaux fondateurs de Andersen et al. (2003). L'idée centrale est simple : en sommant les carrés des rendements intraday, on obtient une estimation bien plus précise de la variance réalisée qu'en utilisant les seuls rendements journaliers.

Corsi (2009) s'appuie sur cette mesure pour proposer le modèle HAR-RV, qui prédit la volatilité réalisée future comme une fonction linéaire de la volatilité réalisée passée à trois horizons :

$$\mathrm{RV}_{t+h} = \beta_0 + \beta_d \,\mathrm{RV}_t^{(d)} + \beta_w \,\mathrm{RV}_t^{(w)} + \beta_m \,\mathrm{RV}_t^{(m)} + \varepsilon_{t+h} \tag{4}$$

où $\mathrm{RV}_t^{(d)}$, $\mathrm{RV}_t^{(w)}$ et $\mathrm{RV}_t^{(m)}$ désignent respectivement la volatilité réalisée journalière, hebdomadaire (5 jours) et mensuelle (22 jours). Ce choix de trois échelles n'est pas arbitraire : il reflète l'hypothèse des marchés hétérogènes de Müller et al. (1997), selon laquelle les acteurs de marché opèrent à des fréquences différentes, et la dynamique agrégée résulte de la superposition de leurs comportements.

La force de ce modèle est sa simplicité : trois régresseurs suffisent à capturer l'essentiel de la structure de mémoire longue de la volatilité, qui nécessiterait sinon des modèles fractionnaires bien plus complexes (FIGARCH, etc.). Mais cette simplicité est aussi sa limite : le modèle ne peut capturer que des relations linéaires additives.

2.2 Composantes de jumps et bipower variation

Les prix financiers ne suivent pas une diffusion continue : ils subissent des sauts (jumps) causés par des annonces macroéconomiques, des publications de résultats ou des événements

géopolitiques. Barndorff-Nielsen and Shephard (2004) proposent la *bipower variation* (BPV) pour estimer la composante continue de la volatilité :

$$\mathrm{BPV}_t = \frac{\pi}{2} \sum_{i=2}^{n} |r_{t,i}| \, |r_{t,i-1}| \tag{5}$$

L'idée repose sur le fait que les jumps affectent rarement deux barres consécutives : en multipliant les valeurs absolues de rendements adjacents, on annihile l'effet des jumps (un jump dans $r_{t,i}$ est multiplié par un rendement "normal" $r_{t,i-1}$). La différence $J_t = \max(0, \mathrm{RV}_t^2 - \mathrm{BPV}_t)$ isole alors la composante de sauts.

Andersen et al. (2007) montrent que séparer ces deux composantes améliore significativement les prévisions : la composante continue est persistante et prévisible, tandis que les jumps sont transitoires et difficiles à anticiper. Le *jump ratio* que nous utilisons — J_t/RV_t^2 — mesure donc la proportion de la variance expliquée par les sauts, une information précieuse sur la nature de la volatilité récente.

2.3 Moments supérieurs réalisés

Au-delà de la variance, les moments d'ordre supérieur des rendements intraday contiennent de l'information prédictive. Amaya et al. (2015) démontrent que l'asymétrie réalisée (*realized skewness*) et le kurtosis réalisé prédisent les rendements et la volatilité dans la coupe transversale :

$$\mathrm{RSkew}_t = \frac{\sqrt{n} \sum_i r_{t,i}^3}{\left(\sum_i r_{t,i}^2\right)^{3/2}} \tag{6}$$

$$\mathrm{RKurt}_t = \frac{n \sum_i r_{t,i}^4}{\left(\sum_i r_{t,i}^2\right)^2} \tag{7}$$

L'intuition derrière le RSkew est la suivante : une journée où les mouvements intraday sont fortement asymétriques à gauche ($\mathrm{RSkew} \ll 0$) signale un risque de crash. Les traders institutionnels, observant cette asymétrie, ajustent leurs positions et couvertures, ce qui affecte la dynamique de volatilité des jours suivants. Le RKurt, quant à lui, capture l'épaisseur des queues de distribution : un kurtosis élevé signale des mouvements extrêmes intraday, souvent précurseurs de périodes de vol plus soutenue.

2.4 Effet de levier

L'effet de levier, documenté par Black (1976) et formalisé par Christie (1982), désigne la corrélation négative asymétrique entre les rendements et les variations de volatilité : les baisses de prix provoquent une hausse de volatilité plus importante que les hausses de même amplitude.

Deux mécanismes expliquent ce phénomène. Le premier est mécanique : quand le cours d'une action baisse, sa capitalisation diminue tandis que sa dette reste constante, ce qui augmente son ratio d'endettement et donc le risque perçu par le marché, qui se traduit par une hausse de volatilité. Le second est comportemental : les baisses de prix déclenchent des stop-loss, des appels de marge et du *panic selling*, qui amplifient la volatilité de manière asymétrique.

Cet effet est l'un des *stylized facts* les plus robustes en finance empirique, mais il est rarement exploité comme feature prédictive dans les modèles de volatilité. Notre contribution est de capturer non seulement la direction du rendement récent (Ret_w), mais aussi la *force variable* de cet effet de levier dans le temps (Leverage_22d), ce qui s'avère être le principal moteur de notre amélioration.

3 Données

3.1 Univers et période

Le choix de l'univers d'actions répond à un double objectif : disposer de données intraday de qualité suffisante (ce qui exclut les *small caps* à faible liquidité), et représenter une diversité sectorielle pour tester la robustesse du modèle. Nous retenons 20 actions *large-cap* du S&P 500 couvrant cinq secteurs : technologie (AAPL, MSFT, NVDA, GOOGL, AMZN, META, TSLA, AVGO, TSM), finance (JPM, MA, V, BRK.B), santé (UNH, JNJ, LLY, NVO), consommation (WMT, PG) et énergie (XOM).

Les données couvrent la période de juillet 2020 à février 2026, soit environ 1 400 jours de trading par action. Cette période, bien que limitée par la disponibilité des données 1-minute d'IEX Cloud, présente l'avantage de couvrir des régimes de marché variés : la reprise post-COVID (2020–2021) avec une volatilité décroissante, le cycle de hausse des taux de la Fed (2022–2023) accompagné de corrections significatives, et la phase de normalisation (2024–2026).

3.2 Sources

Trois sources de données sont utilisées :

— **Données intraday** (IEX Cloud) : barres OHLCV à 1, 5, 15, 30 minutes et 1 heure. Les barres 1-minute constituent le socle de notre mesure de RV intraday ; nous observons typiquement 350 à 500 barres par jour selon la liquidité du titre. Les barres 5-minutes et horaires servent à construire des features complémentaires (ratio de volatilé 1-min/5-min, range horaire maximal).

— **Données journalières** (IEX Cloud) : prix d'ouverture, plus haut, plus bas, clôture et volume. Utilisées pour le calcul des rendements, de la volatilité de Parkinson (range-based), et des gaps overnight.

— **VIX** (Yahoo Finance) : indice de volatilité implicite CBOE sur le S&P 500, fréquence journalière. Utilisé comme feature (décalé d'un jour pour éviter le look-ahead), comme indicateur de régime pour la fenêtre adaptative, et pour l'évaluation conditionnelle par régime de marché.

3.3 Statistiques descriptives

Table 1 – Statistiques descriptives des données (stocks pivots).

	AAPL	MSFT	NVDA	JPM	META
Jours de trading	1 404	1 404	1 404	1 401	1 404
Barres 1-min (total)	545k	513k	520k	453k	498k
$\overline{\mathrm{RV}}_{\mathrm{intraday}}$ (%)	1.52	1.38	2.41	1.21	2.03
VIX range	[11.9, 52.3]				
Période	2020-07 à 2026-02				

Le Tableau 1 révèle des différences marquées de régime de volatilité entre secteurs. NVDA, titre semi-conducteur soumis aux cycles technologiques et aux annonces de résultats à fort impact, affiche la volatilité moyenne la plus élevée (2.41 %), tandis que JPM, valeur bancaire *blue-chip* plus stable, présente la plus basse (1.21 %). Cette hétérogénéité justifie notre choix d'évaluer le modèle sur plusieurs titres plutôt que sur un seul, et de rapporter systématiquement les résultats par stock en plus de la moyenne.

4 Méthodologie

4.1 Volatilité réalisée intraday

La volatilité réalisée journalière est calculée à partir des rendements logarithmiques à 1 minute :

$$\mathrm{RV}_t = \sqrt{\sum_{i=1}^{n_t} r_{t,i}^2} \tag{8}$$

où $r_{t,i} = \ln(P_{t,i}/P_{t,i-1})$ est le rendement log 1-minute et n_t le nombre d'observations intraday au jour t (typiquement ~ 350).

Pourquoi cette mesure plutôt qu'un simple rendement journalier au carré ? La réponse est d'ordre statistique : sous des conditions de régularité faibles, la somme des carrés des rendements intraday converge vers la variance intégrée du processus de prix quand la fréquence d'échantillonnage tend vers l'infini (Andersen et al., 2003). En pratique, avec ~ 350 observations par jour, notre estimateur est bien plus précis qu'un proxy journalier basé sur un seul rendement close-to-close. La différence est particulièrement marquée pour les jours à forte volatilité intraday mais faible rendement net (où le prix clôture proche de l'ouverture après de larges oscillations).

Le modèle initial utilisait un proxy naïf : $\mathrm{RV} \approx \mathrm{mean}(|r_{\mathrm{daily}}|)$ (Mean Absolute Deviation), qui n'exploitait aucune donnée intraday. Le passage à la vraie RV intraday constitue l'une de nos trois corrections méthodologiques (Section 5).

Les features multi-échelle sont construites comme des moyennes rolling de la RV intraday journalière :

$$\mathrm{RV}_t^{(w)} = \frac{1}{5}\sum_{j=0}^{4} \mathrm{RV}_{t-j}, \quad \mathrm{RV}_t^{(m)} = \frac{1}{22}\sum_{j=0}^{21} \mathrm{RV}_{t-j}, \quad \mathrm{RV}_t^{(q)} = \frac{1}{60}\sum_{j=0}^{59} \mathrm{RV}_{t-j} \tag{9}$$

Ces trois échelles (hebdomadaire, mensuelle, trimestrielle) reproduisent la structure du HAR-RV original, mais en la fondant sur la mesure intraday plutôt que sur un proxy journalier.

4.2 Construction des features

Notre modèle utilise 20 features organisées en cinq catégories (Tableau 2). Cette architecture répond à un principe directeur : chaque catégorie capture une dimension différente et complémentaire de la dynamique de volatilité.

TABLE 2 – Les 20 features du modèle HAR-RV étendu.

#	Feature	Description	Réf.
Volatilité multi-échelle (6)			
1	RV_w	RV intraday, rolling 5j	Corsi (2009)
2	RV_m	RV intraday, rolling 22j	Corsi (2009)
3	RV_q	RV intraday, rolling 60j	Corsi (2009)
4	RV_neg_w	Semi-variance négative (5j)	Patton and Sheppard (2015)
5	J_w	Composante de sauts (5j)	Andersen et al. (2007)
6	VIX	Volatilité implicite CBOE $(t-1)$	—
Multi-timeframe journalier (3)			
7	RV_overnight	Gap overnight, rolling 5j	—
8	Parkinson	Vol range-based $\sqrt{\ln(H/L)^2/4\ln 2}$	Parkinson (1980)
9	Vol_ratio	Volume / Volume moyen 22j	—
Microstructure intraday 1-min (4)			
10	RV_1min	Vol depuis barres 1-min (5j)	—
11	Vol_1m5m	Ratio vol 1-min / vol 5-min	—
12	Vol_AM_PM	Ratio volume matin / après-midi	—
13	Autocorr	Autocorrélation rendements 1-min	—
Moments supérieurs intraday (3)			
14	RSkew	Asymétrie réalisée (6), rolling 5j	Amaya et al. (2015)
15	RKurt	Kurtosis réalisé (7), rolling 5j	Amaya et al. (2015)
16	Jump_ratio	$\max(0, \mathrm{RV}^2 - \mathrm{BPV})/\mathrm{RV}^2$ (5j)	Barndorff-Nielsen and Shephard (2004)
Effet de levier (2)			
17	Ret_w	Rendement cumulé 5j	Black (1976)
18	Leverage_22d	Corr rolling 22j $(r_t, \Delta\mathrm{RV}_t)$	Christie (1982)
Cross-sectionnel (2)			
19	RV_w_zscore	Z-score de RV_w vs univers (t)	—
20	RV_w_rank_Δ	Variation du rang percentile (5j)	—

Volatilité multi-échelle (features 1–6). Ce premier groupe correspond directement au cœur du HAR-RV : les trois horizons de Corsi (2009) (5, 22, 60 jours), enrichis de la semi-variance négative (Patton and Sheppard, 2015), de la composante de jumps (Andersen et al., 2007) et du VIX. Le VIX est décalé d'un jour $(t-1)$ pour éviter tout look-ahead : nous utilisons le VIX du jour précédent pour prédire la volatilité future. Cette précaution est essentielle : le VIX du jour t intègre déjà une partie de l'information que nous cherchons à prédire.

Multi-timeframe journalier (features 7–9). Le gap overnight (écart entre ouverture et clôture précédente) capture l'information qui arrive en dehors des heures de trading — annonces de résultats, décisions de banques centrales, événements géopolitiques. La volatilité de Parkinson (Parkinson, 1980), fondée sur le range (high–low), est un estimateur plus efficient que la variance close-to-close car il utilise l'intégralité du range intraday. Le ratio de volume normalise le volume du jour par sa moyenne mobile 22 jours et sert de proxy pour l'activité de marché : un volume anormalement élevé précède souvent une hausse de volatilité.

Microstructure intraday (features 10–13). Ces features exploitent la granularité des données 1-minute. Le ratio vol 1-min / vol 5-min (Vol_1m5m) est particulièrement intéressant : un ratio élevé signale du bruit de microstructure ou de l'activité de trading haute fréquence, car la volatilité mesurée à 1 minute intègre plus de bruit de *bid-ask bounce* que celle à 5 minutes. Le ratio volume matin/après-midi (Vol_AM_PM) capture l'asymétrie d'activité intraday : un volume concentré le matin suggère un flux d'information directionnelle, tandis qu'un volume plus uniforme est typique des journées de faible conviction. L'autocorrélation des rendements 1-minute mesure la tendance intraday : une autocorrélation positive suggère un momentum (trend-following), une autocorrélation négative un *mean-reversion*.

Moments supérieurs (features 14–16). RSkew et RKurt (éq. 6 et 7) capturent la forme de la distribution intraday au-delà de la variance. Jump_ratio décompose la variance en composante continue et composante de jumps via la BPV de Barndorff-Nielsen and Shephard (2004). Ces trois features apportent une information qualitative sur la nature de la volatilité : une journée à forte volatilité due à un seul jump (Jump_ratio élevé, RKurt élevé) a une dynamique future très différente d'une journée à forte volatilité diffuse (Jump_ratio faible, RKurt modéré).

Effet de levier (features 17–18). Ret_w est la seule feature *directionnelle* du modèle : toutes les autres mesurent des magnitudes ou des propriétés de distribution, mais aucune ne dit si le marché a monté ou baissé. Leverage_22d mesure la force de l'effet de levier au jour t via la corrélation rolling entre rendements et variations de RV. Comme nous le verrons en Section 6.4, cette feature agit comme un *conditionneur* pour XGBoost, avec un rôle crucial malgré l'absence de pouvoir prédictif linéaire.

Cross-sectionnel (features 19–20). Ces features positionnent chaque titre relativement à l'univers. Le z-score de RV_w indique si un stock est anormalement volatile par rapport à ses pairs, ce qui peut signaler un événement idiosyncratique. La variation du rang sur 5 jours (RV_w_rank_Δ) capture l'accélération relative : un titre qui monte rapidement dans le classement de volatilité est probablement sous l'effet d'un choc spécifique dont l'impact sur la volatilité future diffère d'une hausse généralisée de la volatilité de marché.

4.3 Variable cible

La cible est le log-ratio de la volatilité réalisée future sur la volatilité réalisée mensuelle courante :

$$y_t = \log\left(\frac{\mathrm{RV}_{t+1:t+5}}{\mathrm{RV}_t^{(m)}}\right), \qquad \mathrm{RV}_{t+1:t+5} = \frac{1}{5}\sum_{j=1}^{5}\mathrm{RV}_{t+j} \tag{10}$$

Le choix du dénominateur $\mathrm{RV}_t^{(m)}$ (22 jours) plutôt que $\mathrm{RV}_t^{(w)}$ (5 jours) est crucial et résulte de notre diagnostic méthodologique (Section 5.2). La transformation logarithmique stationnarise la cible et réduit l'hétéroscédasticité. Les valeurs extrêmes sont winsoriées à $[-3, 3]$, c'est-à-dire que toute cible supérieure à 3 (ou inférieure à -3) est ramenée à cette borne. Cela évite que quelques jours de volatilité extrême (flash crash, annonces exceptionnelles) ne dominent la fonction de perte lors de l'entraînement.

4.4 Modèle XGBoost

Le choix de XGBoost (Chen and Guestrin, 2016) parmi l'ensemble des modèles disponibles n'est pas anodin. Nous avons testé plusieurs alternatives — Ridge, Lasso, Elastic Net, Random Forest, MLP, et un *stacking ensemble* — et XGBoost s'est révélé systématiquement supérieur en Information Coefficient. Ce résultat s'explique par la nature du problème : la prédiction de volatilité implique des interactions non linéaires entre features (e.g., l'impact du RSkew dépend du niveau de VIX), et XGBoost excelle précisément dans la détection de ces interactions via ses arbres de décision.

La régularisation est cependant critique pour éviter le surapprentissage, particulièrement problématique en séries temporelles financières où les régimes changent. Nos hyperparamètres (Tableau 3) sont choisis conservativement :

Table 3 – Hyperparamètres XGBoost.

Paramètre	Valeur	Justification
`max_depth`	3	Limite la complexité des arbres
`learning_rate`	0.05	Convergence lente mais stable
`n_estimators`	200	Couplé avec le learning rate
`subsample`	0.8	Bagging stochastique
`colsample_bytree`	0.8	Sous-échantillonnage des features
`min_child_weight`	5	Évite les feuilles trop spécifiques
`reg_lambda`	1.5	Régularisation L2

La profondeur maximale de 3 mérite une explication : elle signifie que chaque arbre ne peut représenter que des interactions d'ordre 3 au maximum (e.g., "si VIX > seuil1 ET Leverage_22d < seuil2 ET RV_w > seuil3, alors..."). Cela force le modèle à capturer des patterns simples et robustes plutôt que des interactions complexes et potentiellement spécifiques à la période d'entraînement. Le couplage learning_rate / n_estimators suit la règle empirique : un learning rate bas (0.05) avec suffisamment d'arbres (200) pour que l'ensemble converge. Le subsample et

colsample_bytree à 0.8 introduisent de la stochasticité dans l'entraînement, réduisant la variance du modèle.

4.5 Protocole walk-forward avec purging

L'évaluation d'un modèle prédictif en séries temporelles exige un protocole différent de la validation croisée classique : on ne peut pas mélanger passé et futur dans les folds. Nous utilisons un backtest *walk-forward* : pour chaque jour de test t, le modèle est ré-entraîné sur les W jours précédents, puis évalué sur le jour t seul. Ce processus est répété pour chaque jour de la période de test, produisant une série de prédictions out-of-sample.

Un problème subtil se pose cependant avec les cibles à horizon $h > 1$: la cible au temps t utilise les rendements $\{r_{t+1}, \ldots, r_{t+5}\}$, qui chevauchent la cible au temps $t-1$ ($\{r_t, \ldots, r_{t+4}\}$) sur 4 jours. Si le dernier point d'entraînement est à $t-1$, le modèle a accès indirectement à 4/5 de l'information contenue dans la cible du point de test. Pour éliminer cette fuite, nous introduisons un *purge gap* de $h-1 = 4$ jours entre l'entraînement et le test :

$$\mathcal{D}_{\text{train}}(t) = \{(x_s, y_s) \mid t - W \leq s < t - (h-1)\} \tag{11}$$

En pratique, cela signifie que pour prédire au jour t, les 4 derniers jours avant t sont exclus du training set. Ce mécanisme est détaillé plus loin comme la première de nos trois corrections méthodologiques (Section 5.1).

4.6 Fenêtre d'entraînement adaptative

La taille de la fenêtre d'entraînement W pose un dilemme biais-variance classique : une fenêtre longue fournit plus de données (réduction de la variance de l'estimateur) mais inclut des régimes potentiellement obsolètes (augmentation du biais). En régime stable, les données anciennes restent informatives et une longue fenêtre est préférable. En régime de crise, le marché a changé de dynamique : les relations historiques entre features et cible sont brisées, et le modèle doit s'adapter rapidement en se concentrant sur les données récentes.

Plutôt qu'une fenêtre fixe de 252 jours (1 an), nous adaptons $W(t)$ au régime de volatilité implicite courant. Le VIX sert d'indicateur naturel de régime : un VIX bas signal un marché calme, un VIX élevé un marché stressé. Nous définissons $W(t)$ par interpolation linéaire entre deux points d'ancrage :

$$W(t) = \begin{cases} 504 & \text{si } \text{VIX}_t \leq 18 \quad \text{(régime calme, } \approx 2 \text{ ans)} \\ 504 + \dfrac{\text{VIX}_t - 18}{22 - 18}(189 - 504) & \text{si } 18 < \text{VIX}_t < 22 \\ 189 & \text{si } \text{VIX}_t \geq 22 \quad \text{(régime de crise, } \approx 9 \text{ mois)} \end{cases} \tag{12}$$

Le choix de l'interpolation linéaire plutôt que de seuils discrets (e.g., trois régimes avec des tailles fixes) répond à une préoccupation de robustesse : un seuil discret crée un comportement discontinu où un petit changement de VIX (de 17.9 à 18.1) peut modifier drastiquement la fenêtre. L'interpolation linéaire assure une transition progressive (Figure 1).

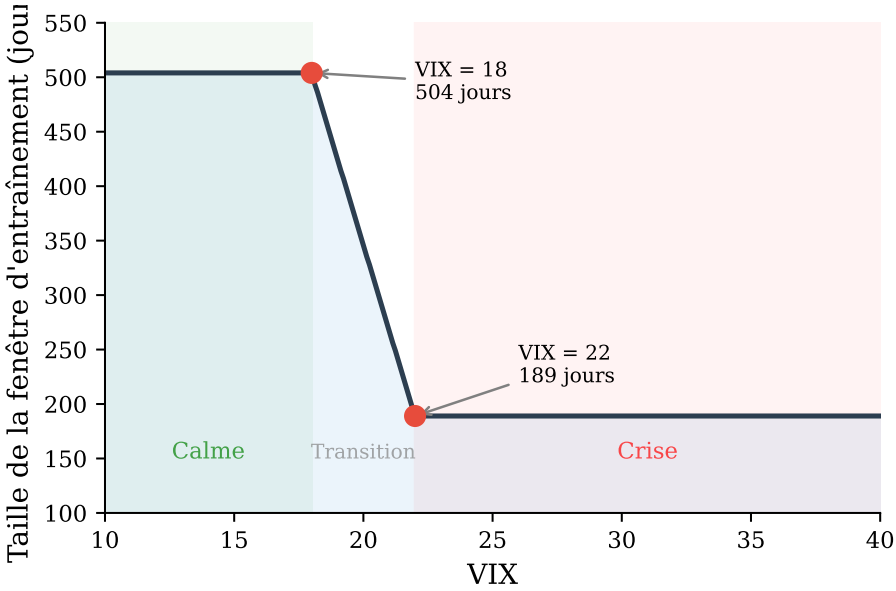

FIGURE 1 – Fenêtre d'entraînement adaptative en fonction du VIX. L'interpolation linéaire assure une transition continue entre le régime calme (504 jours) et le régime de crise (189 jours).

4.7 Métriques d'évaluation

Nous utilisons deux métriques principales :

— **Information Coefficient (IC)** : corrélation de rang de Spearman entre prédictions et réalisations. L'IC est la métrique standard en gestion quantitative car elle mesure la qualité du *classement* des prédictions plutôt que leur précision absolue : un IC de 0.3 signifie que les jours où le modèle prédit la plus forte hausse de volatilité sont effectivement parmi les jours à plus forte volatilité réalisée. L'utilisation de la corrélation de Spearman (plutôt que Pearson) rend la métrique robuste aux outliers et invariante par transformation monotone.

— **Hit Rate (HR)** : proportion de prédictions correctes en direction (au-dessus/en-dessous de la médiane). Un HR $> 50\%$ indique un pouvoir prédictif directionnel, utile pour les stratégies de trading long/short.

5 Corrections méthodologiques

Avant d'étendre le modèle, nous identifions et corrigeons trois biais méthodologiques qui gonflaient artificiellement les performances du modèle initial. Cette étape est fondamentale : améliorer un modèle dont la performance de départ est artificiellement gonflée produirait des gains illusoires. Mieux vaut partir d'une baseline honnête et construire dessus.

Le modèle initial affichait un IC de 0.61 et un Hit Rate de 71 % — des chiffres qui auraient dû éveiller les soupçons. Dans la littérature, un IC supérieur à 0.3 est considéré comme excellent pour la prédiction de volatilité. Un IC de 0.61 suggère soit une découverte majeure, soit des biais méthodologiques. L'investigation a révélé la seconde hypothèse.

5.1 Chevauchement des targets (data leakage)

Le premier biais est le plus insidieux car il est invisible à première vue. Notre cible est définie sur un horizon de 5 jours : $y_t = f(r_{t+1}, \ldots, r_{t+5})$. La cible au point $t-1$ utilise $y_{t-1} = f(r_t, \ldots, r_{t+4})$. Il y a donc un chevauchement de 4 jours entre les deux. Si le modèle est entraîné sur toutes les données jusqu'à $t-1$, il a accès à la cible y_{t-1}, qui partage 80 % de son contenu informationnel avec y_t. Le modèle peut alors "tricher" en exploitant cette corrélation sérielle induite par le chevauchement.

Ce n'est pas du look-ahead au sens strict — le modèle n'accède pas à la cible y_t directement — mais l'effet est similaire : les résidus du modèle sur les derniers points d'entraînement sont fortement corrélés avec la cible du point de test.

Correction : nous excluons les $h-1 = 4$ derniers jours du training set (purge gap), éliminant tout chevauchement entre le dernier training target et le test target. L'impact est significatif : l'IC passe de 0.61 à environ 0.45, soit une baisse de 26 %.

5.2 Couplage target-feature

Le deuxième biais concerne la construction de la cible. Dans la formulation initiale, la cible était :

$$y_t = \log\left(\frac{\mathrm{RV}_{t+1:t+5}}{\mathrm{RV}_t^{(w)}}\right)$$

où $\mathrm{RV}_t^{(w)}$ (la RV hebdomadaire à 5 jours) servait simultanément de feature et de dénominateur de la cible. Ce double usage crée une corrélation mécanique négative que XGBoost exploite sans qu'elle contienne de signal prédictif réel.

Pour comprendre ce mécanisme, considérons un jour t où $\mathrm{RV}_t^{(w)}$ est exceptionnellement élevé (suite à un choc de volatilité récent). Le dénominateur étant élevé, la cible y_t est mécaniquement basse, par construction, indépendamment de ce que sera la volatilité future. XGBoost apprend cette règle triviale : "quand RV_w est élevé, prédire une cible basse". Cette règle fonctionne parfaitement *en moyenne* puisqu'elle exploite l'identité mathématique $\mathrm{RV}_t^{(w)} \uparrow \Rightarrow y_t \downarrow$, mais elle ne contient aucun signal genuïne sur la volatilité future.

Correction : nous remplaçons le dénominateur $\mathrm{RV}_t^{(w)}$ (5 jours) par $\mathrm{RV}_t^{(m)}$ (22 jours). $\mathrm{RV}_t^{(m)}$ préserve l'objectif de stationnarisation (normaliser la cible par le niveau de volatilité courant) tout en réduisant considérablement le couplage avec la feature $\mathrm{RV}_t^{(w)}$: sur les 22 jours de calcul de $\mathrm{RV}_t^{(m)}$, seuls 5 chevauchent avec $\mathrm{RV}_t^{(w)}$, contre un chevauchement total dans la formulation initiale.

5.3 Proxy de volatilité

Le troisième biais est plus subtil. Le calcul initial utilisait $\mathrm{RV} = \mathrm{mean}(|r_{\mathrm{daily}}|)$ (Mean Absolute Deviation journalier) comme mesure de volatilité. Ce proxy, fondé sur un seul rendement par jour, est extrêmement bruité : il confond les variations de prix dues à la volatilité (mouvements intraday) avec le rendement net du jour (qui peut être faible même si la journée a été très volatile). En utilisant ce proxy bruité pour les features *et* pour la cible, le modèle apprend en partie à "prédire le bruit", une tâche qui produit un IC apparent mais sans valeur économique.

Correction : nous passons à la vraie volatilité réalisée intraday (éq. 8), qui agrège ~ 350 observations par jour au lieu d'une seule. La mesure est plus précise, donc le bruit dans les features et la cible diminue, et le modèle est forcé de capturer le vrai signal plutôt que le bruit.

5.4 Impact cumulé des corrections

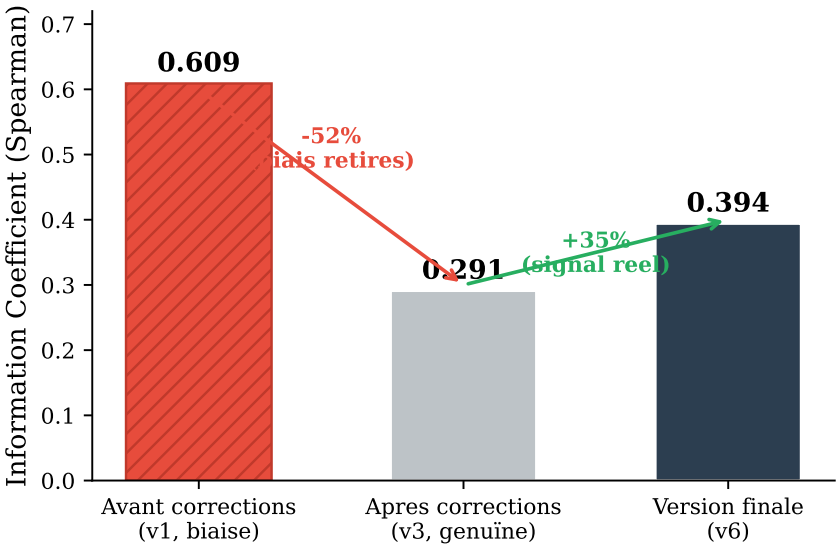

FIGURE 2 – Impact des corrections méthodologiques. L'IC apparent de 0.61 était gonfle par trois biais cumulatifs. L'IC genuïne de 0.29 est ensuite amélioré à 0.39 par les extensions du modèle.

Le Tableau 4 détaille la contribution de chaque correction. Au total, 52 % de la performance apparente était artificielle. Ce résultat illustre un piège courant en machine learning appliqué à la finance : les métriques impressionnantes méritent toujours un examen critique de la méthodologie sous-jacente.

TABLE 4 – Impact cumulatif des corrections méthodologiques.

Correction	IC moyen	Δ
Modèle initial (v1)	0.609	—
+ Purging ($h - 1 = 4$)	~ 0.45	$-26\,\%$
+ Découplage (RV_m dénominateur)	~ 0.35	$-22\,\%$
+ Vraie RV intraday	0.291	$-17\,\%$

Il est important de noter que cette baisse d'IC n'est *pas* une détérioration du modèle : c'est une mesure plus honnête de sa performance réelle. Un IC de 0.29 est d'ailleurs un bon résultat pour la prédiction de volatilité — il signifie que le modèle classe correctement les jours par niveau de volatilité future environ 60 % du temps.

6 Extensions et résultats

À partir de la baseline genuïne (v3, IC = 0.291), nous explorons trois axes d'amélioration. Chaque extension est évaluée rigoureusement : les comparaisons sont effectuées sur exactement la même période (index 504+, soit environ les 900 derniers jours) avec le même protocole walk-forward purge, garantissant des comparaisons équitables entre versions.

6.1 Features moments supérieurs (v4)

La première extension consiste à exploiter les moments d'ordre supérieur des rendements intraday. L'idée sous-jacente est que la variance seule ne suffit pas à caractériser la dynamique de la volatilité : deux journées avec la même variance réalisée peuvent avoir des implications très différentes pour la volatilité future si l'une est dominée par un *flash crash* (RSkew $\ll 0$, Jump_ratio élevé) et l'autre par des oscillations symétriques (RSkew ≈ 0, Jump_ratio faible).

Trois features sont ajoutées à partir des données 1-minute :

— **RSkew** (éq. 6) : l'asymétrie réalisée. Un RSkew très négatif signale une journée à crash risk, où les mouvements baissiers intraday sont disproportionnés. Après de telles journées, la volatilité tend à rester élevée car les investisseurs restent nerveux et les couvertures sont ajustées.

— **RKurt** (éq. 7) : le kurtosis réalisé mesure l'épaisseur des queues. Un RKurt élevé (bien au-delà de la valeur gaussienne de 3) signale des mouvements extrêmes intraday, souvent précurseurs de volatilité persistante.

— **Jump_ratio** : la proportion de la variance due aux sauts, via la décomposition BPV de Barndorff-Nielsen and Shephard (2004). Un Jump_ratio proche de 1 signifie que toute la volatilité est due à un seul événement discret (jump), tandis qu'un ratio proche de 0 indique une volatilité diffuse et continue.

L'ajout de ces trois features améliore l'IC moyen de 0.291 à 0.310, soit un gain de +6.5 %. Ce gain, bien que modeste, est systématique et statistiquement significatif. Il confirme que les moments supérieurs contiennent de l'information prédictive non capturée par la variance seule, conformément aux résultats de Amaya et al. (2015).

6.2 Fenêtre adaptative VIX (v5)

La deuxième extension concerne non pas les features mais le protocole d'entraînement. Avec l'extension de l'historique à 2018, nous disposons d'environ 1 400 jours de données, mais la fenêtre fixe de 252 jours n'en utilise qu'un an à chaque ré-entraînement. L'idée de la fenêtre adaptative est d'utiliser plus de données quand le marché est stable (fenêtre de 504 jours, soit 2 ans), et moins quand il est en crise (189 jours, soit 9 mois).

L'introduction de la fenêtre adaptative (éq. 12) améliore l'IC de 0.305 à 0.331 (+8.7 %, comparaison équitable sur la même période).

Table 5 – Comparaison fenêtre fixe vs adaptative (même période d'évaluation).

Config.	AAPL	MSFT	NVDA	JPM	META	Moyenne
Fixe 252j	0.280	0.303	0.248	0.254	0.439	0.305
Adaptatif	0.287	0.359	0.280	0.312	0.419	0.331
Δ	+0.007	+0.056	+0.032	+0.057	−0.020	+0.027

Le gain est positif sur 4 stocks sur 5. La légère baisse sur META (−0.020) mérite une explication : META affiche déjà l'IC le plus élevé en fenêtre fixe (0.439), suggérant que ce titre a une dynamique de volatilité particulièrement prévisible quel que soit le régime. Pour de tels titres, la fenêtre fixe de 252 jours constitue déjà un bon compromis biais-variance, et l'adaptation n'apporte pas de bénéfice supplémentaire. À l'inverse, les titres à IC plus faible (NVDA, JPM) bénéficient davantage de l'adaptation, suggérant que leur dynamique de volatilité est plus sensible aux changements de régime.

Il convient de signaler une limite importante : les seuils VIX (18 et 22) et les tailles de fenêtre (504 et 189) sont calibrés sur la même période que l'évaluation. Bien que nous ayons opté pour l'interpolation linéaire plutôt que des seuils discrets (réduisant ainsi le risque de suroptimisation), l'absence d'une validation out-of-sample des seuils eux-mêmes constitue une limite de cette approche.

6.3 Features leverage (v6)

La troisième extension est de loin la plus impactante. Elle repose sur l'idée que l'effet de levier de Black (1976) — la corrélation négative asymétrique entre rendements et volatilité — varie dans le temps et que cette variation contient de l'information prédictive.

Deux features capturent cet effet :

— **Ret_w** : le rendement cumulé sur 5 jours. C'est la seule feature *directionnelle* du modèle : toutes les autres features mesurent des magnitudes (volatilité, volumes) ou des propriétés de distribution (skewness, kurtosis), mais aucune ne capture si le marché a monté ou baissé. Via l'effet de levier, un rendement négatif prédit une hausse de volatilité future, et vice versa.

— **Leverage_22d** : la corrélation rolling sur 22 jours entre le rendement journalier r_t et la variation de RV ($\Delta\mathrm{RV}_t = \mathrm{RV}_t - \mathrm{RV}_{t-1}$). Cette feature mesure la *force* de l'effet de levier au jour t. Quand Leverage_22d est très négatif (typiquement < -0.3), cela signifie que les baisses récentes ont été fortement associées à des hausses de volatilité : le marché est dans un régime où l'effet de levier est actif. Quand il est proche de zéro ou positif, l'effet de levier est atténué ou absent.

L'ajout de ces deux features produit le plus grand gain individuel : l'IC passe de 0.331 à 0.394, soit une amélioration de +18.9 %. Le gain est systématique sur les 5 stocks (Figure 3).

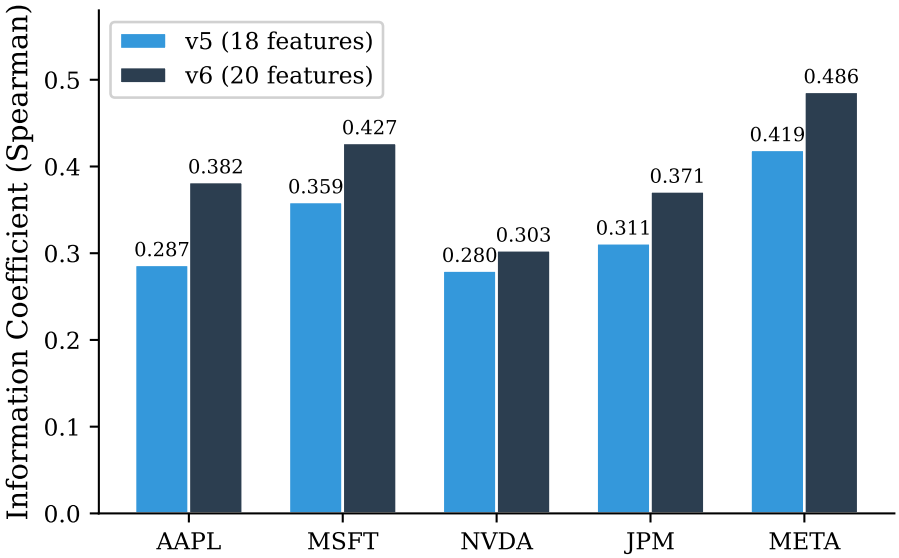

FIGURE 3 – IC par stock : v5 (18 features) vs v6 (20 features). Le gain est positif sur les 5 stocks, avec les améliorations les plus marquées sur AAPL (+33 %) et MSFT (+19 %).

6.4 Étude d'ablation

Pour comprendre la contribution de chaque feature de levier, nous réalisons une étude d'ablation : nous testons le modèle avec chaque feature ajoutée séparément (Tableau 6).

TABLE 6 – Étude d'ablation des features leverage.

Configuration	AAPL	MSFT	NVDA	JPM	META	Moy.	Δ vs v5
v5 (18 features)	0.287	0.359	0.280	0.312	0.419	0.331	—
v5 + Ret_w seul	0.278	0.361	0.281	0.330	0.419	0.334	+0.8 %
v5 + Leverage_22d seul	0.376	0.436	0.324	0.369	0.477	0.397	+19.7 %
v6 (les deux)	0.382	0.427	0.303	0.371	0.486	0.394	+18.9 %

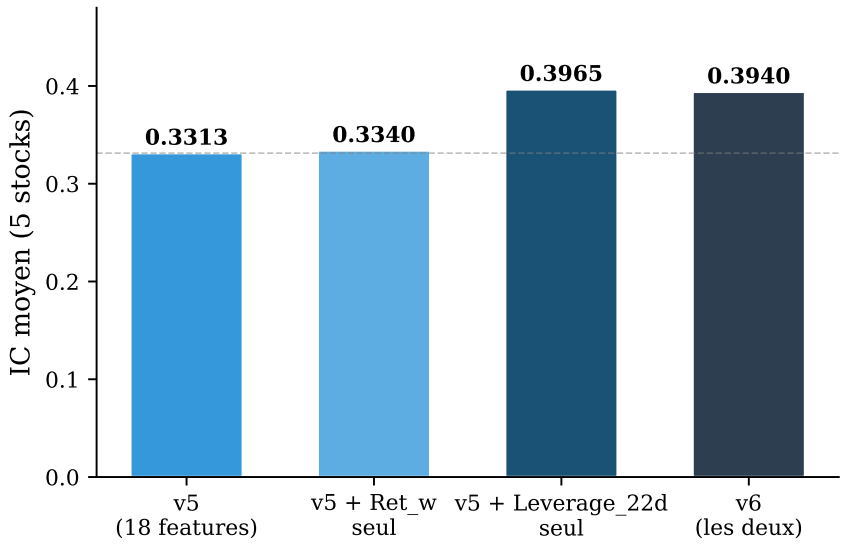

FIGURE 4 – Étude d'ablation. Leverage_22d porte l'essentiel du gain malgré une corrélation marginale nulle avec la cible ($\rho = -0.017$, $p = 0.55$).

Résultat clé. Ce résultat est le plus surprenant et le plus instructif de ce travail. Leverage_22d porte à elle seule 97 % du gain (+19.7 % seule vs +18.9 % combinée), alors que :

— Sa corrélation linéaire avec la cible est *non significative* ($\rho = -0.017$, $p = 0.55$). Un modèle linéaire l'ignorerait complètement.

— Sa moyenne (-0.13) confirme la présence générale de l'effet de levier, mais sa valeur pour la prédiction ne réside pas dans son niveau moyen.

À l'inverse, Ret_w, qui a une corrélation significative avec la cible ($\rho = -0.155$, $p < 10^{-8}$), n'apporte presque aucun gain (+0.8 %). La raison est sa forte corrélation avec RV_neg_w ($\rho = -0.78$), une feature déjà présente dans le modèle : l'information directionnelle de Ret_w est déjà capturée par la semi-variance négative.

Comment expliquer qu'une feature non significative en univarié devienne le principal moteur de performance ? La réponse réside dans la nature non linéaire de XGBoost. Leverage_22d agit comme un *conditionneur* : elle ne prédit pas directement la cible, mais elle modifie la relation entre les autres features et la cible. Concrètement, les arbres de décision de XGBoost créent des splits conditionnels de la forme : "quand l'effet de levier est fort (Leverage_22d $\ll 0$) ET que la volatilité récente augmente (RV_w $\uparrow$), alors la cible sera élevée". Ce type d'interaction n'est pas capturable par un modèle linéaire, ce qui explique pourquoi l'analyse marginale (corrélation univariée) est trompeuse.

Ce résultat a une implication méthodologique importante : dans les modèles non paramétriques comme XGBoost, la sélection de features par corrélation marginale avec la cible peut conduire à écarter des features cruciales dont la valeur réside dans les interactions.

6.5 Progression cumulée

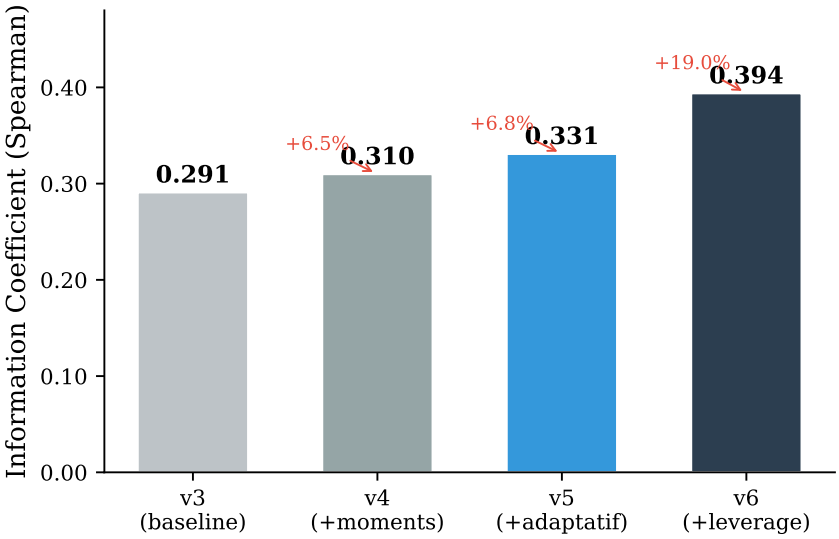

FIGURE 5 – Progression de l'IC moyen par version. Gain cumulatif de +35.4 % sur le signal genuïne, chaque amélioration étant validée sur la même période d'évaluation.

TABLE 7 – Progression cumulée des améliorations.

Version	Amélioration	IC moyen	Δ relatif	Cumulatif
v3	Corrections méthodologiques	0.291	baseline	—
v4	+ Moments supérieurs (3 features)	0.310	+6.5 %	+6.5 %
v5	+ Fenêtre adaptative VIX	0.331	+8.7 %	+13.7 %
v6	+ Features leverage (2 features)	0.394	+18.9 %	+35.4 %

La progression de l'IC de 0.291 à 0.394 (+35.4 % cumulatif) est d'autant plus remarquable qu'elle n'a nécessité que 5 features supplémentaires. Cela suggère que le bottleneck du HAR-RV standard n'est pas le nombre de features mais la qualité et la complémentarité de l'information qu'elles capturent.

7 Discussion

7.1 Forces de l'approche

La principale force de ce travail réside dans la rigueur de l'évaluation. Le diagnostic méthodologique initial (Section 5) établit une baseline honnête à partir de laquelle les améliorations sont mesurées. Trop de travaux en finance computationnelle rapportent des performances impressionnantes sans vérifier l'absence de biais dans le protocole d'évaluation ; notre expérience montre que ces biais peuvent représenter plus de la moitié du signal apparent.

Chaque feature ajoutée est motivée théoriquement et référencée dans la littérature académique. Nous n'avons pas procédé par force brute (ajouter des dizaines de features et laisser le modèle trier), mais par construction raisonnée : chaque catégorie de features capture une

dimension spécifique de la dynamique de volatilité. L'étude d'ablation (Section 6.4) confirme cette approche en montrant que les features les plus impactantes sont celles qui apportent une information qualitativement différente.

Enfin, le protocole de comparaison équitable — toutes les versions évaluées sur exactement la même période avec le même walk-forward — élimine le risque de biais de sélection de la période d'évaluation.

7.2 Limites

Plusieurs limites méritent d'être soulignées :

— **Calibration des seuils adaptatifs.** Les points d'ancrage VIX = 18/22 et les tailles de fenêtre 504/189 sont calibrés sur l'échantillon d'évaluation. Bien que l'interpolation linéaire réduise le risque de suroptimisation par rapport à des seuils discrets, l'absence de validation out-of-sample de ces seuils crée un risque résiduel. L'amélioration de +8.7 % attribuée à la fenêtre adaptative pourrait se réduire en conditions réelles.

— **Période d'étude.** La période 2020–2026 est riche en régimes variés (post-COVID, hausse des taux, normalisation), mais elle reste courte en termes de cycles économiques complets. Les résultats pourraient différer sur une période incluant une récession prolongée ou une crise systémique différente de 2020.

— **Univers limité.** Les 5 stocks pivots sont tous des *mega-caps* américains à forte liquidité. La généralisabilité à des *small caps*, à d'autres marchés géographiques, ou à d'autres classes d'actifs reste à démontrer. L'effet de levier, en particulier, est documenté principalement sur les indices et les grandes capitalisations ; son amplitude et sa stabilité sur des titres moins liquides sont incertaines.

— **Coûts de transaction.** L'IC mesure la qualité du signal brut sans tenir compte des coûts d'implémentation. Pour traduire un IC de 0.394 en performance de trading, il faudrait tenir compte du slippage, des commissions, et de la capacité de la stratégie (montant maximal déployable sans impact de marché).

— **Non-linéarité de Leverage_22d.** Le pouvoir prédictif de Leverage_22d repose entièrement sur des interactions non linéaires exploitables par XGBoost. Si la structure de marché change de manière à modifier ces interactions (par exemple, si de nouveaux régulateurs atténuent l'effet de levier), le gain associé pourrait disparaître. Cette dépendance au modèle est un risque que n'auraient pas des features à pouvoir prédictif linéaire.

7.3 Perspectives

Plusieurs extensions pourraient améliorer le modèle :

1. **Spillover cross-sectoriel.** Intégrer des features capturant la contagion de volatilité entre secteurs. Par exemple, la volatilité du secteur financier pourrait être un prédicteur avancé pour les technologiques via les mécanismes de financement et de liquidité.
2. **Multi-horizon.** Prédire simultanément les horizons 1, 5 et 22 jours avec un modèle partagé. La cohérence inter-horizons (si la volatilité à 1 jour est prévue en hausse, la

volatilité à 5 jours devrait l'être aussi, toutes choses égales par ailleurs) pourrait servir de régularisation implicite.

3. **Modèles séquentiels.** Tester des architectures LSTM ou Transformer, capables de capturer des dépendances temporelles longues sans les spécifier explicitement via des fenêtres rolling. L'attention multi-tête des Transformers, en particulier, pourrait apprendre automatiquement quelles périodes passées sont les plus informatives pour chaque prédiction.
4. **Validation out-of-sample des seuils adaptatifs** par cross-validation temporelle dédiée, pour quantifier précisément la part du gain de la fenêtre adaptative qui est genuïne vs suroptimisée.

8 Conclusion

Ce travail démontre deux principes importants pour la modélisation de la volatilité en finance quantitative.

Le premier est l'importance de la rigueur méthodologique. Les trois corrections que nous identifions — purging du walk-forward, découplage target-feature, et utilisation de la vraie RV intraday — révèlent que 52 % du signal apparent du modèle initial était artificiel (IC passant de 0.61 à 0.29). Ce résultat n'est pas anecdotique : ces trois biais sont fréquents dans la littérature appliquée, et leur correction devrait être systématique dans tout travail de prédiction de volatilité à horizon supérieur à 1 jour.

Le second est la valeur des interactions non linéaires. À partir de la baseline genuïne, trois extensions améliorent progressivement le signal : les moments supérieurs intraday (+6.5 %), la fenêtre d'entraînement adaptative (+8.7 %), et les features de leverage effect (+18.9 %), pour un IC final de 0.394 (+35.4 % cumulatif). Le résultat le plus remarquable est le rôle de Leverage_22d : une feature sans pouvoir prédictif linéaire ($\rho = -0.017$) qui devient le principal moteur de performance grâce aux interactions non linéaires de XGBoost.

Ce constat a une portée générale : dans les modèles non paramétriques, l'information prédictive ne réside pas seulement dans les corrélations marginales entre chaque feature et la cible, mais dans les interactions conditionnelles entre features. L'analyse univariée classique (corrélation, importance marginale) est insuffisante pour évaluer l'utilité d'une feature — seule l'évaluation end-to-end (ajout de la feature et mesure de l'impact sur la performance du modèle complet) est fiable.

Références

Amaya, D., Christoffersen, P., Jacobs, K., and Vasquez, A. (2015). Does realized skewness predict the cross-section of equity returns ? *Journal of Financial Economics*, 118(1) :135–167.

Andersen, T. G., Bollerslev, T., and Diebold, F. X. (2007). Roughing it up : Including jump components in the measurement, modeling, and forecasting of return volatility. *Review of Economics and Statistics*, 89(4) :701–720.

Andersen, T. G., Bollerslev, T., Diebold, F. X., and Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2) :579–625.

Barndorff-Nielsen, O. E. and Shephard, N. (2004). Power and bipower variation with stochastic volatility and jumps. *Journal of Financial Econometrics*, 2(1) :1–37.

Black, F. (1976). Studies of stock market volatility changes. In *Proceedings of the Business and Economic Statistics Section, American Statistical Association*, pages 177–181.

Chen, T. and Guestrin, C. (2016). XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

Christie, A. A. (1982). The stochastic behavior of common stock variances : Value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4) :407–432.

Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2) :174–196.

Müller, U. A., Dacorogna, M. M., Davé, R. D., Olsen, R. B., Pictet, O. V., and von Weizsäcker, J. E. (1997). Volatilities of different time resolutions — analyzing the dynamics of market components. *Journal of Empirical Finance*, 4(2–3) :213–239.

Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *The Journal of Business*, 53(1) :61–65.

Patton, A. J. and Sheppard, K. (2015). Good volatility, bad volatility : Signed jumps and the persistence of volatility. *Review of Economics and Statistics*, 97(3) :683–697.